

Relatório T2 Machine Learning

Identificação de Dígitos

Igor Alves, Luigi Gabriel, Matheus Homrich, Nathan Schostack, Thiago Mello

1. Introdução

A identificação de dígitos é uma tarefa fundamental na área de reconhecimento de padrões e visão computacional. Nesse contexto, este trabalho tem como objetivo desenvolver um sistema de identificação de dígitos manuscritos utilizando o conjunto de dados MNIST, uma referência na comunidade de aprendizado de máquina.

Para a implementação desse sistema, foi utilizado o Jupyter Notebook, e a biblioteca Keras para a construção e treinamento de redes neurais.

O conjunto de dados MNIST consiste em 70.000 imagens de dígitos manuscritos, divididas em um conjunto de treinamento com 60.000 exemplos e um conjunto de teste com 10.000 exemplos. Cada imagem é representada por uma matriz de pixels em escala de cinza, com dimensões de 28x28 pixels. O objetivo é treinar um modelo de aprendizado de máquina capaz de classificar corretamente os dígitos representados nas imagens.

2. Metodologia

Este trabalho irá explorar o conjunto de dados MNIST utilizando o Jupyter Notebook e a biblioteca Keras, buscando desenvolver um modelo eficiente de identificação de dígitos. A partir do treinamento do modelo, serão avaliadas suas métricas de desempenho, como acurácia e perda, para verificar sua capacidade de generalização e precisão na classificação dos dígitos. Fizemos o trabalho com base no código disponível no repositório <https://github.com/wxs/keras-mnist-tutorial>.

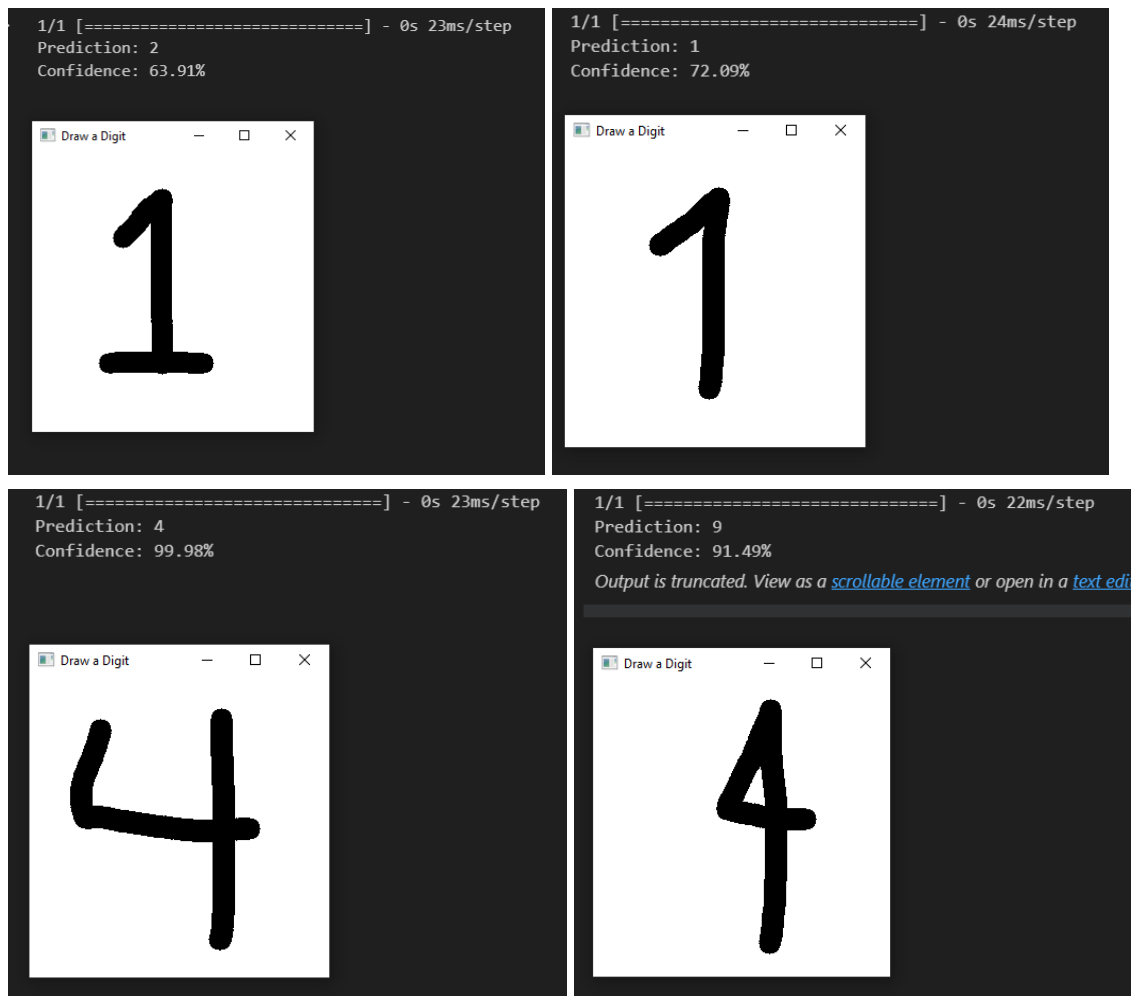
A partir dele, adicionamos código para que o usuário pudesse desenhar números para serem classificados pela rede neural.

O código base para testar o modelo MNIST e nossa versão alterada para que o usuário possa desenhar dígitos estão disponíveis no seguinte repositório:

<https://github.com/TGVM/T2ML>.

3. Resultados

Podemos notar que alguns números quando desenhados costumavam ser classificados de maneira errada. O número 4, como pode ser visto nas imagens abaixo, podendo ser desenhado de duas maneiras diferentes, acabava sendo classificado como um 9 em vários testes. Outro número que obteve classificações erradas várias vezes foi o 7, pois dependendo do ângulo do desenho, recebia uma classificação 1. Os outros números também obtiveram classificações erradas nos testes, porém com menos frequência. Abaixo alguns exemplos executados pelo nosso grupo:



Algumas melhorias que poderiam ter sido feitas para tentar obter classificações melhores nos testes são: Aumentar o número de épocas de treinamento, aumentar o tamanho do modelo, ajustar a taxa de aprendizagem ou aumentar o conjunto de treinamento.

4. Conclusão

Por fim, tivemos como objetivo neste trabalho entender o funcionamento de uma rede neural com o uso do dataset MNIST e utilizando uma modificação pequena na aplicação para fazer novos testes de classificação. Para trabalhos futuros que expandem este estudo, poderíamos tentar adicionar a detecção de letras, assim como é feito no dataset “*Handwriting recognition*”, em combinação com o MNIST, para ter mais diversidade nos inputs possíveis de serem classificados.

Bibliografia

KERAS. Keras: MNIST digits classification dataset. Disponível em:
<<https://keras.io/api/datasets/mnist/>>. Acesso em: 18 de jun. de 2023

Keras. Keras: Handwriting recognition. Disponível em:
<https://keras.io/examples/vision/handwriting_recognition/>. Acesso em: 18 de jun. de 2023